

Laporan Praktikum 4 Kontrol Cerdas

Nama : Teuku Muhammad Rafli

NIM : 224308022

Kelas : TKA-6A

Akun Github (Tautan) : <https://github.com/rafli969>

Student Lab Assistant : Rizky Putri Ramadhani (214308092)

1. Judul Percobaan

Melatih dan Menguji Agen Reinforcement Learning Untuk Mengontrol Lingkungan Secara Otonom

2. Tujuan Percobaan

Tujuan dari percobaan pada praktikum kali ini, sebagai berikut:

1. Mahasiswa dapat memahami Konsep dasar dari Reinforcement Learning (RL) dalam sistem kendali.
2. Mahasiswa dapat mempelajari cara mengimplementasikan RL menggunakan algoritma Deep Q-Network (DQN).
3. Mahasiswa dapat mempelajari bagaimana cara melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.

3. Landasan Teori

Reinforcement Learning merupakan proses pemetaan situasi dalam suatu lingkungan (states) ke dalam tindakan (behavior) dengan tujuan memaksimalkan reward. Dalam hal ini, agen yang berperan sebagai pembelajar tidak diberi tahu secara langsung tindakan apa yang harus dilakukan, melainkan belajar secara mandiri melalui pengalaman. Salah satu konsep utama dalam Reinforcement Learning adalah Agent. Agent dalam Reinforcement Learning (RL) adalah entitas atau program yang mengambil keputusan serta berinteraksi dengan lingkungan untuk mencapai suatu tujuan. Agent melakukan tindakan, menerima umpan balik, dan belajar dari pengalaman untuk meningkatkan performanya. Peran utama Agent meliputi mengamati lingkungan, memilih tindakan, menerima feedback, dan menyesuaikan strateginya. Oleh karena itu, Agent menjadi elemen kunci dalam Reinforcement Learning, di mana ia bertindak berdasarkan pengamatan lingkungan, memperoleh reward, serta terus belajar guna meningkatkan kemampuannya.

Deep Q-Network (DQN) merupakan algoritma dalam Reinforcement Learning yang menggabungkan Q-learning dengan jaringan saraf dalam guna menyelesaikan permasalahan kompleks. Algoritma ini memungkinkan agent untuk belajar dari pengalaman dan mengambil keputusan dalam lingkungan yang rumit. DQN sangat bermanfaat dalam menangani permasalahan dengan ruang keadaan yang besar, seperti pengenalan gambar dan kontrol robot, karena memanfaatkan kemampuan jaringan saraf dalam mengekstrak fitur dari data secara efektif dan efisien. Cara kerja DQN melibatkan pemanfaatan jaringan saraf untuk memperkirakan nilai Q, yaitu nilai dari setiap tindakan yang dapat diambil dalam suatu keadaan tertentu. Dengan

menerapkan teknik pemutaran ulang pengalaman (experience replay), DQN menyimpan pengalaman masa lalu dalam memori dan mengambil sampel acak dari pengalaman tersebut untuk memperbarui model, sehingga meningkatkan stabilitas serta efisiensi pembelajaran. Selain itu, DQN juga menggunakan strategi eksplorasi epsilon-greedy, yang membantu agent menyeimbangkan antara mencoba tindakan baru (eksplorasi) dan memanfaatkan tindakan yang sudah terbukti efektif (eksploitasi), sehingga memungkinkan agent menemukan strategi optimal seiring waktu.

4. Analisis dan Diskusi

Analisis =

MountainCar-v0 merupakan lingkungan yang menantang dalam Reinforcement Learning karena agen harus mengembangkan strategi yang tidak langsung untuk mencapai tujuan. Dengan adanya reward negatif untuk setiap langkah yang diambil, agen terdorong untuk menemukan solusi yang efisien. Tantangan utama dalam lingkungan ini adalah ruang keadaan yang kontinu serta kebutuhan untuk membangun momentum agar mobil dapat mencapai puncak bukit. Algoritma tradisional seperti Q-learning kurang efektif dalam menangani ruang keadaan yang besar, sehingga diperlukan pendekatan yang lebih canggih seperti Deep Q-Network (DQN).

Diskusi =



Untuk mengatasi tantangan dalam MountainCar-v0, DQN menjadi pilihan yang tepat karena mampu menangani ruang keadaan yang besar dengan menggunakan jaringan saraf dalam untuk memperkirakan nilai Q. Teknik seperti experience replay membantu meningkatkan stabilitas pembelajaran, sementara strategi eksplorasi epsilon-greedy memungkinkan agen menyeimbangkan antara mencoba tindakan baru dan mengeksploitasi tindakan yang sudah terbukti efektif. Keberhasilan agen dapat diukur berdasarkan efisiensi pergerakan, waktu yang dibutuhkan untuk mencapai puncak, serta stabilitas kebijakan yang diperoleh. Untuk meningkatkan performa agen lebih lanjut, dapat diterapkan modifikasi seperti penyesuaian reward, penggunaan Dueling DQN, atau prioritized experience replay agar proses pembelajaran lebih optimal.

5. Assignment

Pada praktikum ini yaitu implementasi dari algoritma Deep Q-Network (DQN) yang digunakan untuk melatih environment agen dalam environment MountainCar-v0. Tujuan dari agen ini yaitu mencapai puncak bukit dengan menggunakan aksi yang optimal. Kode dimulai dengan mengimpor beberapa library yang diperlukan, seperti gymnasium untuk environment reinforcement learning, numpy untuk operasi numerik, random untuk pemilihan acak, dan deque dari collections untuk menyimpan pengalaman. Selain itu, tensorflow.keras digunakan untuk membangun model jaringan saraf. Selanjutnya, terdapat kelas yang disebut DQNAgent, yang mendefinisikan agen DQN. Agen diinisialisasi dengan ukuran keadaan dan ukuran aksi. Beberapa parameter penting juga digunakan, seperti gamma yang berfungsi sebagai faktor diskon, epsilon yang merupakan parameter untuk eksplorasi, dan learning_rate yang digunakan untuk optimasi model.

Pada eksperimen pertama CartPole-V1, agen harus menjaga tiang tetap tegak di atas gerobak/kotak. Lingkungan ini cukup sederhana, sehingga agen dapat belajar dengan cepat. Setiap kali agen berhasil menjaga tiang tetap tegak, ia mendapatkan reward positif. Pelatihan untuk CartPole bisa dilakukan dalam waktu singkat, hanya dalam beberapa ratus episode. Agen dapat dengan stabil mencapai tujuannya karena lingkungan ini lebih mudah diprediksi. Sedangkan, pada MountainCar-v0, agen harus menggerakkan mobil ke puncak bukit, tetapi mobil tidak memiliki cukup tenaga untuk langsung mencapai tujuan. Agen harus belajar membangun momentum dengan bergerak maju dan mundur. Reward di MountainCar-v0 lebih susah karena mobil tidak berhasil mencapai puncak, yang membuat pembelajaran menjadi lebih sulit. Model yang digunakan memerlukan arsitektur yang lebih kompleks atau teknik tambahan untuk meningkatkan stabilitas. Proses pelatihan untuk MountainCar memerlukan lebih banyak episode. Sebelum agen dapat mencapai kinerja yang baik. Pembaruan nilai dalam lingkungan ini bisa lebih berfluktuasi, sehingga kembali ke skor yang lebih tinggi.

6. Data dan Output Hasil Pengamatan

NO	Variabel	Hasil Pengamatan
1	Hasil Score Test	 <pre> C:\Users\thinkpad_X390\AppData\Local\Programs\Python\Python311\Lib\site- bool8' is a deprecated alias for 'np.bool_'. (Deprecated NumPy 1.24) if not isinstance(terminated, (bool, np.bool8)): Test Episode: 1, Score: 8 Test Episode: 2, Score: 8 Test Episode: 3, Score: 8 Test Episode: 4, Score: 9 Test Episode: 5, Score: 9 Test Episode: 6, Score: 9 Test Episode: 7, Score: 7 Test Episode: 8, Score: 9 Test Episode: 9, Score: 22 Test Episode: 10, Score: 8 Test Episode: 11, Score: 23 Test Episode: 12, Score: 10 Test Episode: 13, Score: 8 Test Episode: 14, Score: 8 Test Episode: 15, Score: 8 Test Episode: 16, Score: 23 Test Episode: 17, Score: 34 Test Episode: 18, Score: 9 Test Episode: 19, Score: 9 Test Episode: 20, Score: 8 PS C:\Bafli\Semester 6\Prak_Kontrol_Cerdas\Week4> </pre>
2	Hasil Run Sim	

7. Kesimpulan

Berdasarkan percobaan yang telah dilakukan, dapat disimpulkan bahwa:

1. Percobaan ini menggunakan TensorFlow untuk membangun model Deep Q-Network (DQN), yang diterapkan dalam pengembangan agen RL. Selain itu, OpenAI Gym digunakan sebagai lingkungan simulasi untuk melatih agen RL.
2. Percobaan ini terdiri dari dua tahap utama, yaitu tahap pelatihan agen, yang bertujuan untuk melatih agen RL, dan tahap pengujian agen, yang digunakan untuk mengevaluasi kinerja agen setelah melalui proses pelatihan.
3. Hasil percobaan menunjukkan bahwa agen belum mampu mengendalikan CartPole dengan baik. Hal ini terlihat dari skor pelatihan yang tidak mengalami peningkatan signifikan serta skor uji yang tetap rendah. Penyebab utama dari hasil ini adalah pemilihan parameter yang kurang optimal, seperti gamma, epsilon, dan learning rate.

8. Saran

Berdasarkan hasil percobaan yang telah dilakukan, terdapat beberapa saran yang dapat diajukan, yaitu:

1. Untuk meningkatkan kinerja agen dalam mengendalikan CartPole, disarankan untuk menyesuaikan parameter, menambah jumlah episode pelatihan, serta menerapkan teknik optimasi. Dengan demikian, agen RL dapat belajar lebih efektif dan mencapai kontrol yang lebih optimal terhadap CartPole.
2. Mengimplementasikan algoritma Deep Q-Network (DQN) dalam berbagai permasalahan di dunia nyata guna mengeksplorasi potensinya dalam menyelesaikan tantangan yang lebih kompleks.

9. Daftar Pustaka

Irvansyah, Muhammad Adhitya. (2020). *IMPLEMENTASI METODE REINFORCEMENT LEARNING PADA SIMULASI PERGERAKAN ROBOT MULTI-SENDI*

Baradja, A., & Tjendrowasono, T. I. (2024). *Pengaplikasian Deep Reinforcement Q-Learning Untuk Prediksi Perdagangan Valas Otomatis*. *Jurnal Rekayasa Sistem Informasi dan Teknologi*, 1(3), 190–198. <https://doi.org/10.59407/jrsit.v1i3.519>
